

Local LLM · RAG

Tự xây trợ lý AI đọc tài liệu của bạn — chạy 100% trên máy

Dữ liệu của bạn không rời máy · PGS.TS. Lê Anh Cường


Mục tiêu buổi học

- **HIỂU** RAG và **6 thành phần** của hệ RAG local
 - **XÂY** RAG local trên tài liệu của bạn — không cần code
 - **CHỌN** model LLM phù hợp, chạy offline bằng **Ollama**
- | *Thước đo: hỏi 1 câu về tài liệu → trả lời **đúng** + **trích nguồn**.*

Rủi ro khi gửi dữ liệu ra ngoài

- **Rò rỉ:** Samsung (5/2023) cấm ChatGPT nội bộ sau lộ mã nguồn
- **Điều khoản:** *"data may be used to improve our models"*
- **Chi phí:** trả **theo token**, phụ thuộc mạng & nhà cung cấp

| *Gửi prompt = gửi dữ liệu ra ngoài tổ chức.*



Giải pháp: LLM local

Dữ liệu **KHÔNG** rời máy.

— **LLM local (Ollama)** là nền tảng → **RAG** lên trên

Nhóm	Nhu cầu
Văn phòng	Tra quy chế nội bộ
Lập trình viên	Trợ lý code offline
Tổ chức/DN	Chatbot không rò rỉ
Y tế	Hồ sơ bệnh nhân bảo mật


Local vs Cloud

Tiêu chí	Local	Cloud / API
Bảo mật	Ở lại máy	Gửi ra ngoài
Chi phí	Trả 1 lần	Theo token
Chất lượng	Model nhẹ	Mô hình mạnh
Độ trễ	Chậm trên CPU	Nhanh (GPU lớn)
Vận hành	Tự bảo trì	Bấm là dùng

Local thắng bảo mật & chi phí, đổi lấy chất lượng & tốc độ.

Lộ trình buổi học

- 1. Nền tảng:** cài & chạy LLM local — Ollama + Docker
 - 2. RAG — trọng tâm:** 6 thành phần → nạp tài liệu → **trích nguồn**
- Cả 2 chặng đều có **thực hành làm theo**.



RAG — Trục chính


RAG là gì

Tra tài liệu trước, **trả lời** sau.

- **LLM** không có tài liệu của bạn
- Hỏi thẳng → **bịa** (hallucination)
- Dán cả tập → **vượt** context, tốn token
- Ấn dụ: **đóng sách** (LLM) → **mở sách** (RAG)

RAG = Retrieval + Augmented + Generation

Kiến trúc RAG: 6 bước




Offline (1 lần): Load → Chunk → Embed → Store

Online (mỗi câu hỏi): Retrieve → Generate

4 bước đầu làm 1 lần · 2 bước cuối chạy mỗi câu hỏi.

Embedding: chữ thành nghĩa



- Mỗi đoạn → vector ~**768 chiều**
- Nghĩa gần → vector **gần** (cosine nhỏ)
- Hưn từ khoá: "mã đăng nhập" $\approx$ "mật khẩu" vẫn **khớp**
- Model **nomi-c-embed-text**, tính local

Chunking, Vector DB, Top-k

- **Chunk** ~300–700 ký tự, overlap 10–20%
- **Vector DB**: vector + text + metadata, HNSW
- **Top-k**: lấy **k** đoạn gần nhất

Thông số	Giá trị
Chunk Size	500
Chunk Overlap	50
Top K	3

Giới hạn & Đánh giá RAG

RAG vẫn có thể sai khi:

- Retrieve **sai đoạn** → "rác vào, rác ra"
- Câu hỏi **ngoài** tài liệu → cần System Prompt chặn
- **Chunking / embedding** kém → cả hệ kém theo

Đánh giá chất lượng:

- **Faithfulness** — câu trả lời bám nguồn, có trích dẫn
- Đọc **Sources** — nguồn không khớp = tín hiệu sai
- Khung bài bản: **RAGAS**

Đo lường được → cải tiến được.

Công cụ & chạy LLM local

Ollama là gì

Phần mềm mã nguồn mở chạy LLM ngay trên máy — "Docker cho LLM".

- **Phổ biến:** kho model cộng đồng, nhiều model **hàng chục-trăm triệu lượt tải**
- **Chuyên nghiệp:** tự tối ưu GPU/CPU · API **tương thích OpenAI** → ghép app dễ
- **Bảo mật:** model + dữ liệu chạy **100% offline**, không gửi gì lên cloud
- **Đơn giản:** cài 1 lệnh, chạy/đổi model 1 dòng

Cài đặt Ollama

Windows (PowerShell):

```
winget install Ollama.Ollama
```

macOS / Linux:

```
curl -fsSL https://ollama.com/install.sh | sh
```

Kiểm tra: chạy **ollama --version**. Yêu cầu **RAM ≥ 8GB**.

Lấy model

Mở ollama.com/library → chọn model theo RAM máy:

RAM	Model	Cỡ
8GB	qwen3:1.7b	~1.4GB
16GB	qwen3:4b	~2.5GB
GPU lớn	qwen3:8b	~5GB

Tải về (kèm embedding cho RAG):

```
ollama pull qwen3:1.7b  
ollama pull nomic-embed-text
```

Số "**b**" $\approx$ độ thông minh $\approx$ độ nặng · **Qwen** hợp tiếng Việt. → 2 slide sau: thư viện & qwen3.

Thư viện model Ollama



Models Docs Pricing

Q

Search models

Sign in

Download



Library

Filter models

Popular

llama3.1

Llama 3.1 is a new state-of-the-art model from Meta available in 8B, 70B and 405B parameter sizes.

tools

8b

70b

405b

↓ 115.3M Pulls

🏷 93 Tags

🕒 Updated 1 year ago

deepseek-r1

DeepSeek-R1 is a family of open reasoning models with performance approaching that of leading models, such as O3 and Gemini 2.5 Pro.

tools

thinking

1.5b

7b

8b

14b

32b

70b

671b

↓ 86.7M Pulls

🏷 35 Tags

🕒 Updated 11 months ago

nomic-embed-text

A high-performing open embedding model with a large token context window.

embedding

↓ 72.5M Pulls

🏷 3 Tags

🕒 Updated 2 years ago

Model qwen3 — chọn cỡ theo RAM

[Models](#)[Docs](#)[Pricing](#)

[Sign in](#)[Download](#)

qwen3

 30M Downloads  Updated 7 months ago

Qwen3 is the latest generation of large language models in Qwen series, offering a comprehensive suite of dense and mixture-of-experts (MoE) models.

[tools](#)[thinking](#)[0.6b](#)[1.7b](#)[4b](#)[8b](#)[14b](#)[30b](#)[32b](#)[235b](#)

[CLI](#)[cURL](#)[Python](#)[JavaScript](#)

```
ollama run qwen3
```



Applications

	Claude Code ollama launch claude --model qwen3	
	Codex App ollama launch codex-app --model qwen3	
	OpenClaw ollama launch openclaw --model qwen3	
	Hermes Agent ollama launch hermes --model qwen3	
	Codex ollama launch codex --model qwen3	
	OpenCode ollama launch opencode --model qwen3	

Chạy & test LLM local


Test nhanh 1 câu:

```
ollama run qwen3:1.7b "Giải thích RAG trong 3 câu"
```

Hoặc mở phiên chat: **ollama run qwen3:1.7b** (dấu nhắc **>>>**, thoát **/bye**).

- Lần đầu **tự tải** model nếu chưa có → trả lời ngay
- **CPU** im 15–25s là bình thường (đang nạp) → sau đó **stream**
- → Kết quả thật như **slide sau**

Kết quả: LLM trả lời offline



```
Windows PowerShell - ollama run qwen3:1.7b

PS C:\Users\Minh Phuc\...\bai-giang> ollama run qwen3:1.7b "Giải thích RAG trong 3 câu"

RAG (Retrieval-Augmented Generation) cho LLM đọc tài liệu của bạn
trước khi trả lời: hệ thống tìm các đoạn liên quan nhất rồi đưa kèm
câu hỏi vào model. Nhờ vậy câu trả lời bám tài liệu, ít bịa, và
trích được nguồn để kiểm chứng.

PS C:\Users\Minh Phuc\...\bai-giang>

[100% offline] qwen3:1.7b (~1.4GB) chạy ngay trên máy • không gọi cloud
```

Thực hành — RAG qua Open WebUI

Nhu cầu giao diện

- **LLM** local đã chạy, 6 bước RAG đã hiểu
- **Terminal** không hợp người dùng hằng ngày
- Cần **giao diện**: lịch sử chat, kéo-thả file, đổi model
- Giải pháp: **Open WebUI** — không cần code

6 bước trong Open WebUI

Open WebUI tự động hóa 6 bước RAG — bạn chỉ chỉnh thông số.

6 bước	Trong Open WebUI
1. Load	Upload / kéo-thả
2. Chunk	Chunk Size
3. Embed	Embedding Model
4. Store	Tự động lưu
5. Retrieve	Top K
6. Generate	Model + Prompt

Open WebUI là gì

- Giao diện chat **mã nguồn mở**, giống ChatGPT, chạy local
- Lịch sử hội thoại, đổi model **1 click**, kéo-thả tài liệu
- Quản trị RAG bằng giao diện — **không cần code**
- Tài liệu + chat lưu volume **open-webui-data** → **không rời máy**

Docker là gì

*Nền tảng **container** — đóng gói phần mềm + mọi thứ nó cần, chạy giống nhau ở mọi máy.*

- **Chuẩn công nghiệp:** hầu hết hệ thống production hiện đại dùng Docker
- **Phổ biến:** hàng triệu lập trình viên · kho image khổng lồ (Docker Hub)
- **Gọn & sạch:** 1 lệnh là có cả Open WebUI · gỡ không để lại rác
- **An toàn:** chạy **cách ly** (isolated), không đụng hệ thống máy bạn

Cài đặt Docker

Tải **Docker Desktop** (miễn phí cá nhân): docker.com/products/docker-desktop

Windows — cần **winget** (sẵn trên Win 10/11):

```
winget install Docker.DockerDesktop
```

macOS — cần **Homebrew** trước (mặc định chưa có → cài tại brew.sh):

```
brew install --cask docker
```

Cài xong → mở **Docker Desktop**, đợi báo "running".

Cài đặt Open WebUI

Docker Desktop phải đang **"running"**. Chọn **1** cách.

Cách 1 — Docker (cấu hình sẵn của repo): chạy trong thư mục repo:

```
docker compose up -d
```

Cách 1b — Docker (cài độc lập, không có repo):

```
docker run -d -p 3000:8080 --add-host=host.docker.internal:host-gateway `
-v open-webui:/app/backend/data --name open-webui ghcr.io/open-webui/open-webui:main
```

→ mở localhost:3000 · lần đầu tải image ~1GB

Cách 2 — pip (không cần Docker):

```
pip install open-webui
open-webui serve          # → mở localhost:8080
```


Khởi động & mở

Kiểm tra trước khi mở:


```
ollama list  
docker ps
```

Mở **localhost:3000** → chọn model **qwen3:1.7b**. Open WebUI **tự nối Ollama** (Settings → Connections).
→ Giao diện & kết nối như **2 slide sau**.

Giao diện Open WebUI



Kết nối Ollama với Open WebUI



Nạp tài liệu • Bước 1: Load

Tạo **Knowledge base** = kho tài liệu của bạn (dùng lại nhiều lần):

1. Vào **Workspace** → **Knowledge** → + **New Knowledge**
2. Đặt tên kho → bấm **Create**
3. Mở kho → bấm + → upload file (.md, .pdf, .docx)
→ 2 slide sau: **màn tạo kho & kho đã có 6 tài liệu.**

Tạo Knowledge base

or

Models Knowledge Prompts Skills Tools

← Back

✎

🔍

📄

⚙️

Create a knowledge base

What are you working on?

Quy chế ATTT (demo)

What are you trying to achieve?

Bộ quy chế an toàn thông tin nội bộ — dữ liệu mẫu của workshop.

🔒 Private

Only select users and groups with permission can access


Access List

+ Add Access

No access grants. Private to you.

Create Knowledge

Kho "Quy chế ATTT" — 6 tài liệu



Chỉnh thông số · Bước 2–3–5

Vào **Admin Panel** → **Settings** → **Documents**:

Tên	Giá trị
Chunk Size	~500
Chunk Overlap	~50
Embedding Model	nomic-embed-text
Top K	3
Hybrid Search	bật cho mã / từ khóa hiếm

→ Bấm **Save** rồi nạp lại tài liệu. 2 slide sau: **mặc định** → **sau khi đổi nomic**.

UsersAnalyticsEvaluationsFunctionsSettings

Q Search

General

Connections

Models

Evaluations

Integrations

Documents

Web Search

Code Execution

Interface

Audio

Images

Pipelines

Database

General

Content Extraction EngineDefault

PDF Extract Images (OCR)

PDF Loader ModePage

Bypass Embedding and Retrieval

Text SplitterDefault (Character)

Markdown Header Text Splitter

Chunk Size1000

Chunk Overlap100

Chunk Min Size Target0

Embedding

Embedding Model EngineDefault (SentenceTransformers)

Embedding Modelsentence-transformers/all-MiniLM-L6-v2

After updating or changing the embedding model, you must reindex the knowledge base for the changes to take effect. You can do this using the "Reindex" button below.

Embedding Batch Size1

Retrieval

Full Context Mode

Hybrid Search

Reranking Batch Size32

Top K3

RAG Template### Task:
Respond to the user query using the provided context, incorporating inline citations in the format [id] **only when the <source> tag includes an explicit id attribute** (e.g., <source id="1">).

Save

Đổi Embedding → nomic-embed-text

oi

✎

🔍

📄

⚙️

👤

Users Analytics Evaluations Functions Settings

🔍 Search

General

⚙️ General

🔗 Connections

📦 Models

📊 Evaluations

🔧 Integrations

📁 Documents

🌐 Web Search

💻 Code Execution

🗨️ Interface

🔊 Audio

🖼️ Images

🔗 Pipelines

🗄️ Database

Content Extraction Engine

PDF Extract Images (OCR)

PDF Loader Mode

Bypass Embedding and Retrieval

Text Splitter

Markdown Header Text Splitter

Chunk Size

1000

Chunk Overlap

100

Chunk Min Size Target

0

Embedding

Embedding Model Engine

http://host.docker.internal:11434

API Key

Embedding Model

nomic-embed-text

After updating or changing the embedding model, you must reindex the knowledge base for the changes to take effect. You can do this using the "Reindex" button below.

Embedding Batch Size

1

Async Embedding Processing

Embedding Concurrent Requests

0

Retrieval

Full Context Mode

Hybrid Search

Reranking Batch Size

32

Top K

3

RAG Template

Save

Trợ lý RAG • Bước 6: Generate

Tạo **model trợ lý riêng** (Workspace → Models → +):

- Base model **qwen3:1.7b** + System Prompt = bước *Generate*
 - System Prompt: *chỉ dùng tài liệu · thiếu → "không đề cập" · trích nguồn*
 - Gắn Knowledge base vào model → khởi gõ **#** mỗi lần
 - Lưu thành **trợ lý** → chọn 1 click, dùng lại mọi lúc
- Slide sau: trợ lý "Quy chế ATTT" với Prompt + Knowledge.

Trợ lý "Quy chế ATTT": Prompt + Knowledge

Trợ lý Quy chế ATTT

Quy trình xử lý sự cố ATTT gồm những bước nào? Liệt kê các bước.

Trợ lý Quy chế ATTT Today at 6:08 PM

Thought for 3 seconds

- Bước 1: Nhận diện sự cố**
 - Truy xuất thông tin về sự cố (ví dụ: thời gian, loại tấn công, nguồn gốc).
 - Nguyên nhân:** Tài liệu không đề cập.
- Bước 2: Giảm thiểu tổn thất**
 - Áp dụng các biện pháp ngăn chặn sự cố (ví dụ: block IP, block domain).
 - Nguyên nhân:** Tài liệu không đề cập.
- Bước 3: Lập kế hoạch phục hồi**
 - Xác định các hệ thống, dữ liệu cần phục hồi.
 - Nguyên nhân:** Tài liệu không đề cập.
- Bước 4: Phục hồi hệ thống**
 - Tái cấu hình, phục hồi dữ liệu, kiểm tra lại hệ thống.
 - Nguyên nhân:** Tài liệu không đề cập.
- Bước 5: Giao tiếp với bên ngoài**
 - Thông báo cho bên liên quan (ví dụ: cơ quan chức năng, đối tác).
 - Nguyên nhân:** Tài liệu không đề cập.

Tài liệu không đề cập.

Follow up

Các bước này có ý nghĩa gì trong quy trình xử lý sự cố ATTT?

Send a Message

Hỏi đáp có trích nguồn

Chọn **trợ lý** vừa tạo → hỏi:

Quy trình xử lý sự cố ATTT gồm những bước nào?

- Trả lời **bám tài liệu**, không bịa
 - **Trích nguồn**: hiện tên file → bấm xem đúng đoạn gốc
 - **Kiểm chứng được** — khác biệt cốt lõi với ChatGPT thường
- 2 slide sau: **truy hồi nguồn** → **câu trả lời có trích dẫn**.

Retrieve: truy hồi đúng nguồn

Open WebUI

New Chat

Search

Notes

Workspace

Folders

Chats

Today

Quy trình xử lý sự cố ATTT g. ...

Quy trình xử lý sự cố ATT... 2m

RAG Explained 2h

Network Security 2h

Previous 7 days

RAG Explained 1d

qwen3:1.7b

Quy trình xử lý sự cố ATTT gồm những bước nào? Hãy trả lời bằng tiếng Việt, liệt kê rõ từng bước.

oi qwen3:1.7b Today at 5:43 PM

Retrieved 2 sources

- Querying
 - Quy trình xử lý sự cố an toàn thông tin
 - Bước xử lý sự cố ATTT trong hệ thống
- Retrieved 2 sources

Thought for 3 seconds

Quy trình xử lý sự cố ATTT được mô tả trong hai cấp độ 03_quy_trinh_su_co.md và 02_phan_loai_tai_lieu.md :

- Cấp độ 0 - Công khai:**
 - Lưu dữ liệu trên hệ thống thông thường 02_phan_loai_tai_lieu.md
 - Cho phép truy cập qua cổng thông tin điện tử.
- Cấp độ 3 - Tuyệt mật:**
 - Lưu dữ liệu trên hệ thống vật lý cách ly (air-gap) 02_phan_loai_tai_lieu.md
 - Tuyệt đối không phép sử dụng thiết bị cá nhân trong khu vực xử lý.
 - Ghi nhật ký tất cả truy cập, lưu trữ 10 năm.

Các bước cụ thể được trình bày theo cấp độ, với các yêu cầu bảo mật tăng dần từ cấp độ 0 đến cấp độ 3. Nếu cần chi tiết hơn, hãy cung cấp thêm thông tin.

2 Sources

Follow up

Các bước cụ thể của cấp độ 0 và cấp độ 3 có khác nhau ở điểm nào?

Mỗi cấp độ có vai trò gì trong quy trình xử lý sự cố ATTT?

Tại sao cần thực hiện các bước bảo mật tăng dần từ cấp độ 0 đến cấp độ 3?

Send a Message

User

Trả lời kèm trích nguồn

Open WebUI

New Chat

Search

Notes

Workspace

Folders

Chats

Today

Quy trình xử lý sự cố ATTT g. ...

Quy trình xử lý sự cố ATT... 2m

RAG Explained 2h

Network Security 2h

Previous 7 days

RAG Explained 1d

qwen3:1.7b +

Quy trình xử lý sự cố ATTT gồm những bước nào? Hãy trả lời bằng tiếng Việt, liệt kê rõ từng bước.

oi

qwen3:1.7b Today at 5:43 PM

Retrieved 2 sources

Thought for 3 seconds

Quy trình xử lý sự cố ATTT được mô tả trong hai cấp độ 03_quy_trinh_su_co.md và 02_phan_loai_tai_lieu.md :

1. Cấp độ 0 - Công khai:

Lưu dữ liệu trên hệ thống thông thường 02_phan_loai_tai_lieu.md .

Cho phép truy cập qua cổng thông tin điện tử.

2. Cấp độ 3 - Tuyệt mật:

Lưu dữ liệu trên hệ thống vật lý cách ly (air-gap) 02_phan_loai_tai_lieu.md .

Tuyệt đối không phép sử dụng thiết bị cá nhân trong khu vực xử lý.

Ghi nhật ký tất cả truy cập, lưu trữ 10 năm.

Các bước cụ thể được trình bày theo cấp độ, với các yêu cầu bảo mật tăng dần từ cấp độ 0 đến cấp độ 3. Nếu cần chi tiết hơn, hãy cung cấp thêm thông tin.

2 Sources

Follow up

Các bước cụ thể của cấp độ 0 và cấp độ 3 có khác nhau ở điểm nào?

Mỗi cấp độ có vai trò gì trong quy trình xử lý sự cố ATTT?

Tại sao cần thực hiện các bước bảo mật tăng dần từ cấp độ 0 đến cấp độ 3?

Send a Message

+ ❖

User

© 2026 · 100% offline

41 / 47


Tinh chỉnh & kiểm chứng

- **Top K** 3 → 5: đầy đặn hơn, chậm hơn
- **Model** 1.7b → 4b: mạch lạc hơn
- **Từ tự nhiên** hợp hơn mã ngắn (P1, MFA)
- Hỏi câu **ngoài** tài liệu → "*Tài liệu không đề cập*" = RAG đúng

Áp dụng & Tổng kết

Thành quả buổi học

- Chạy **LLM** offline — dữ liệu không rời máy
- Xây **RAG** local trên tài liệu của mình
- Trả lời **có trích nguồn** — không cần code



Hệ RAG local — tự xây, không cloud.

Áp dụng trong tổ chức


Dữ liệu	Mục đích	Chọn
Nhạy	Tra cứu nội bộ	Local
Nhạy	Tác vụ phức tạp	Local (4b/8b)
Công khai	Chất lượng tối đa	Cloud

Dữ liệu càng nhạy → ưu tiên Local.

Use case: **HR • Pháp chế • R&D • CSKH**

Checklist bảo mật

- **Phân loại** tài liệu trước khi nạp
- **Redact** PII trước khi index
- **Phân quyền** — WEBUI_AUTH, mỗi người 1 tài khoản
- **Audit log** — ai hỏi gì, truy vấn tài liệu nào



Cảm ơn!

Bạn đã tự xây một hệ RAG local — dữ liệu không rời máy

Hỏi đáp · PGS.TS. Lê Anh Cường